

LINFO 1121 DATA STRUCTURES AND ALGORITHMS



Algorithmes de tri et recherche dichotomique

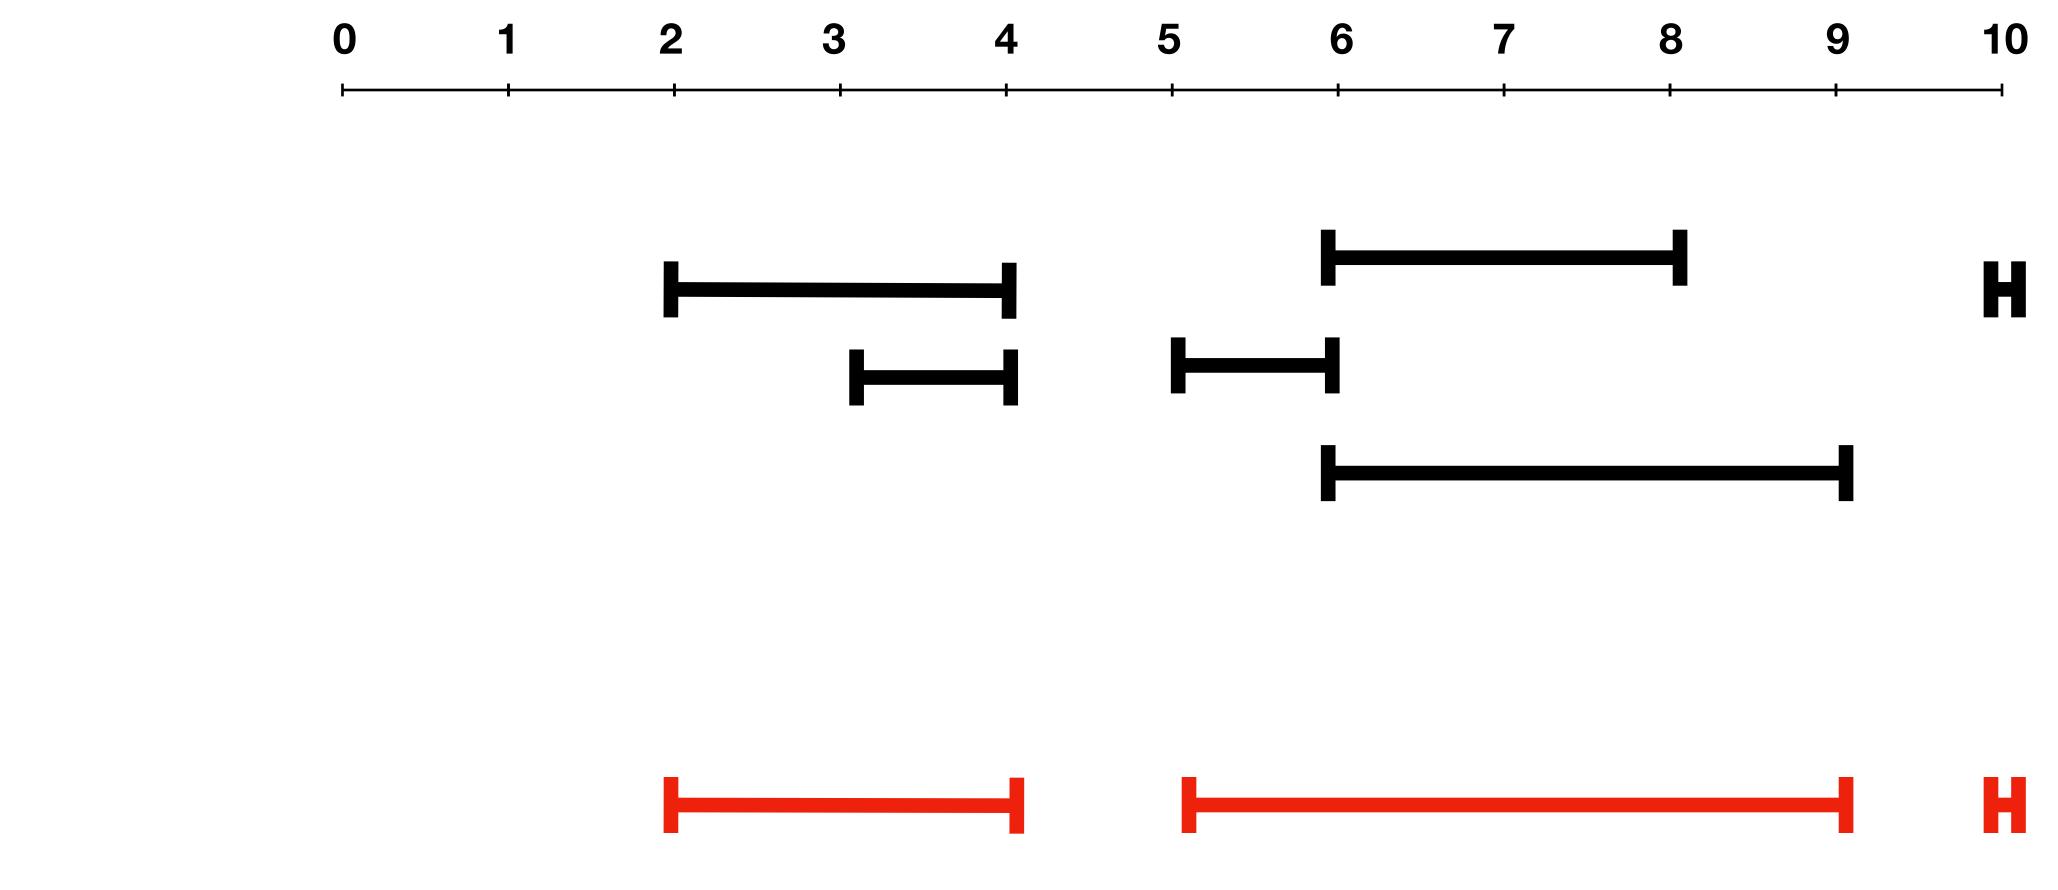
Pierre Schaus

Union d'intervalles

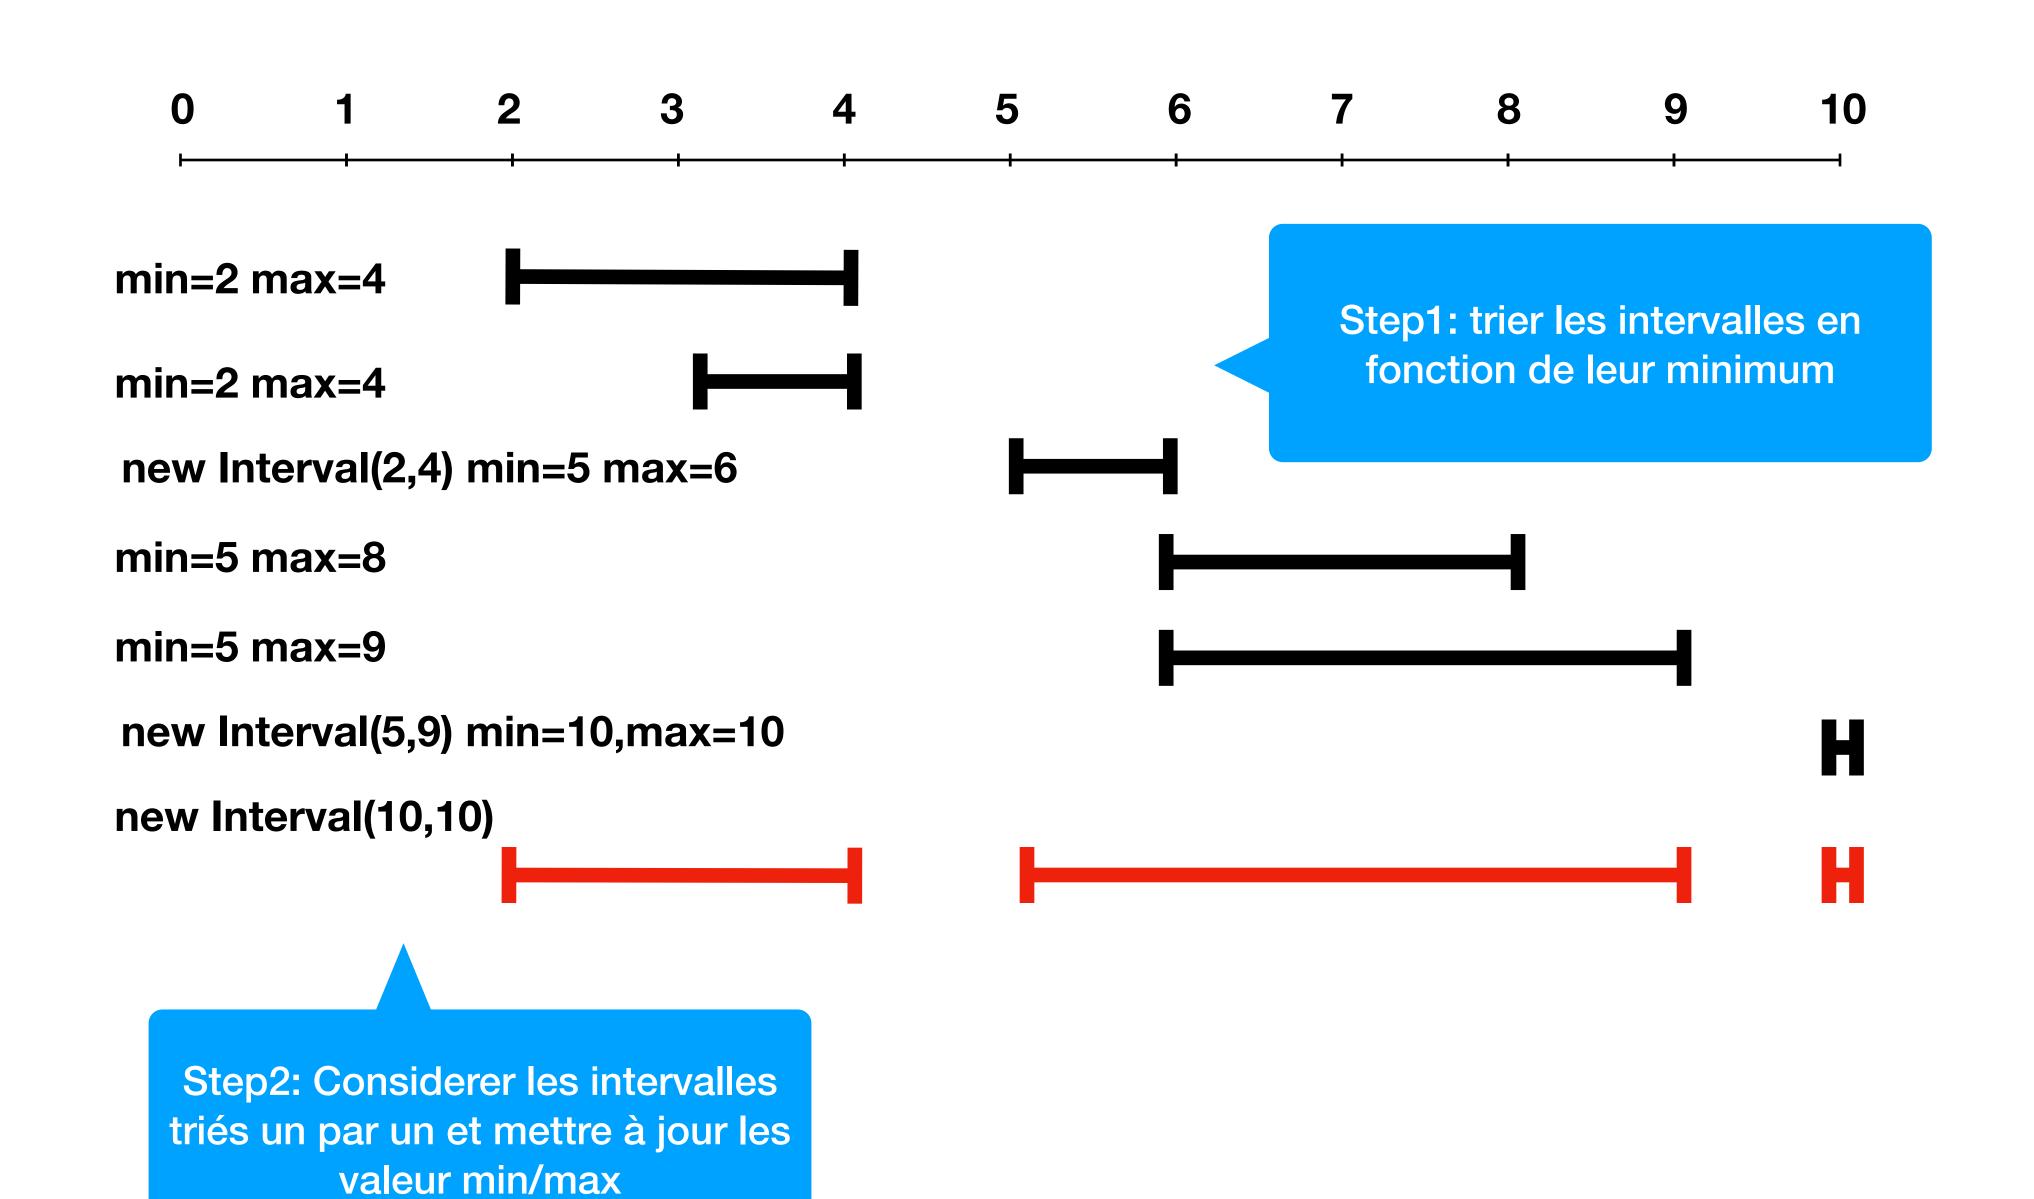
Écrivez une méthode qui prend en entrée un tableau d'intervalles et qui retourne l'union de ces intervalles comme un tableau d'intervalles disjoints. On considère que les intervalles d'input sont donnés sous la forme de deux tableaux *int[] min, int[] max;* où le ième intervalle est donné par (min[i],max[i]). Exemple d'entrée min=[5,0,1,6,2] max=[7,2,2,8,3] donnerait en sortie min=[0,5],max=[3,8].

Ecrivez le pseudo-code. Quelle est la complexité de votre méthode ?

Union of intervals



Input: [10,10],[2,4],[3,4],[5,6],[6,9],[6,8] Output: [2,4],[5,9],[10,10]



Algo1

```
public static Interval [] union(Interval [] intervals) {
    if (intervals.length == 0) return new Interval[0];
    ArrayList<Interval> res = new ArrayList<>();
    Arrays.sort(intervals);
    int min = intervals[0].min;
    int max = intervals[0].max;
    int i = 1;
   while (i < intervals.length) {</pre>
        if (intervals[i].min > max) {
            res_add(new Interval(min,max));
            min = intervals[i].min;
            max = intervals[i].max;
        } else {
            max = Math.max(max,intervals[i].max);
        1++;
    res.add(new Interval(min,max));
    return res.toArray(new Interval[0]);
```

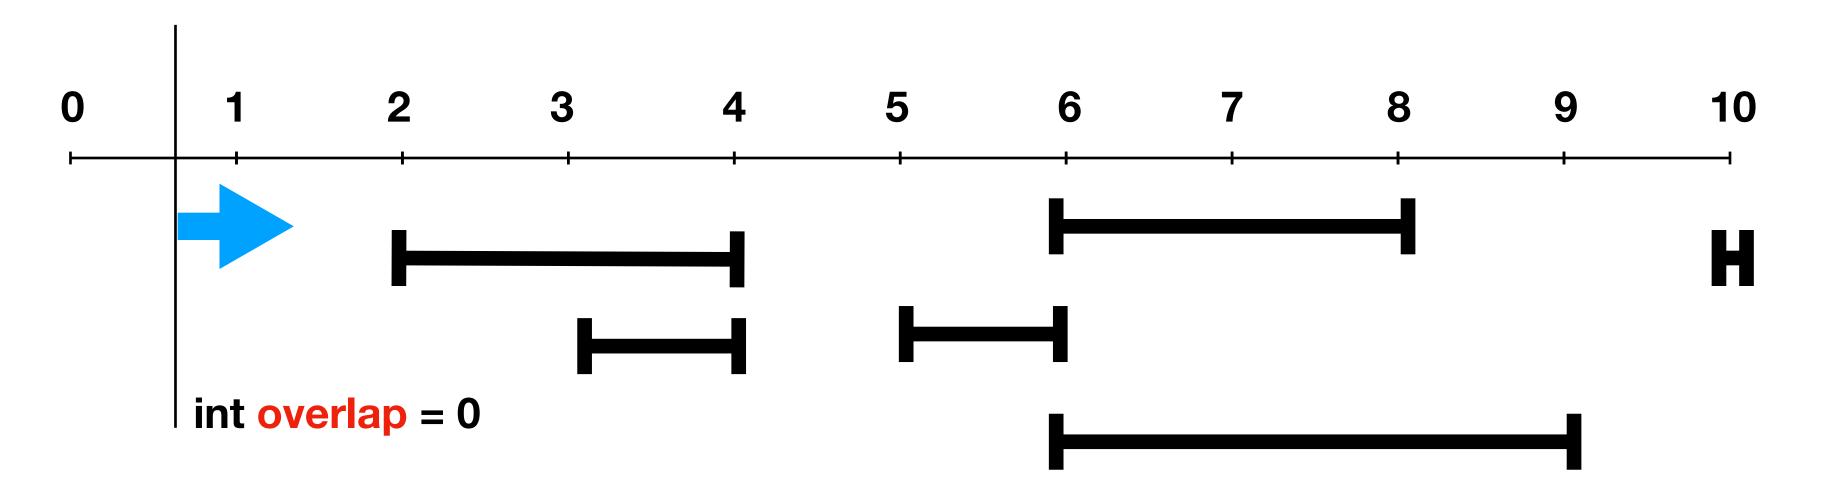
! We change the input, not always considered a good practice

Complexité temporelle ?

- O(n) où n est le nombre d'intervalles en input
- $\Theta(n)$ où n est le nombre d'intervalles en input
- O(n log(n)) où n est le nombre d'intervalles en input
- Θ (n log(n)) où n est le nombre d'intervalles en input



Autre approche: algorithme de Sweep (plus générique)



- On crée une séquence triée d'événements en début et fin d'intervalle:
 - +1 pour ouverture
 - 1 pour fermeture
- (2,+1),(3,+1),(4,-1),(4,-1),(5,+1),(6,+1),(6,+1),(6,-1),(8,-1),(9,-1),(10,+1),(10,-1)
- · Un compteur "overlap" va être maintenu représentant le nombre d'intervalle intersection la ligne de sweep.
- Pour chaque nouveau pas de temps, on traite tous les événements un par un et on met à jour le compteur.
- · Si lorsqu'on a traité tous les événements le compteur est à zero, on a détecté un nouvel intervalle.

Sweep Line Algo: pseudo code

```
public static List<int[]> computeUnion(int[] min, int[] max) {
   int n = min.length;
   Point[] S = new Point[2 * n + 1];
   for (int i = 0; i < n; i++) {
        S[2 * i] = new Point(min[i], 1);
       S[2 * i + 1] = new Point(max[i] + 1, -1);
    S[2 * n] = new Point(Integer. MAX_VALUE, 0);
   Arrays.sort(S);
   List<int[]> union = new ArrayList<>();
    int start = S[0].x;
   int overlap = S[0].delta;
    int i = 1;
   while (i < 2 * n) {</pre>
        overlap += S[i].delta;
       if (overlap == 0) {
            union.add(new int[]{start, S[i].x});
            start = S[i + 1].x;
       i += 1;
    return union;
```

Creation des "event points"

Process des "event points" un à un

Detection d'un intervalle

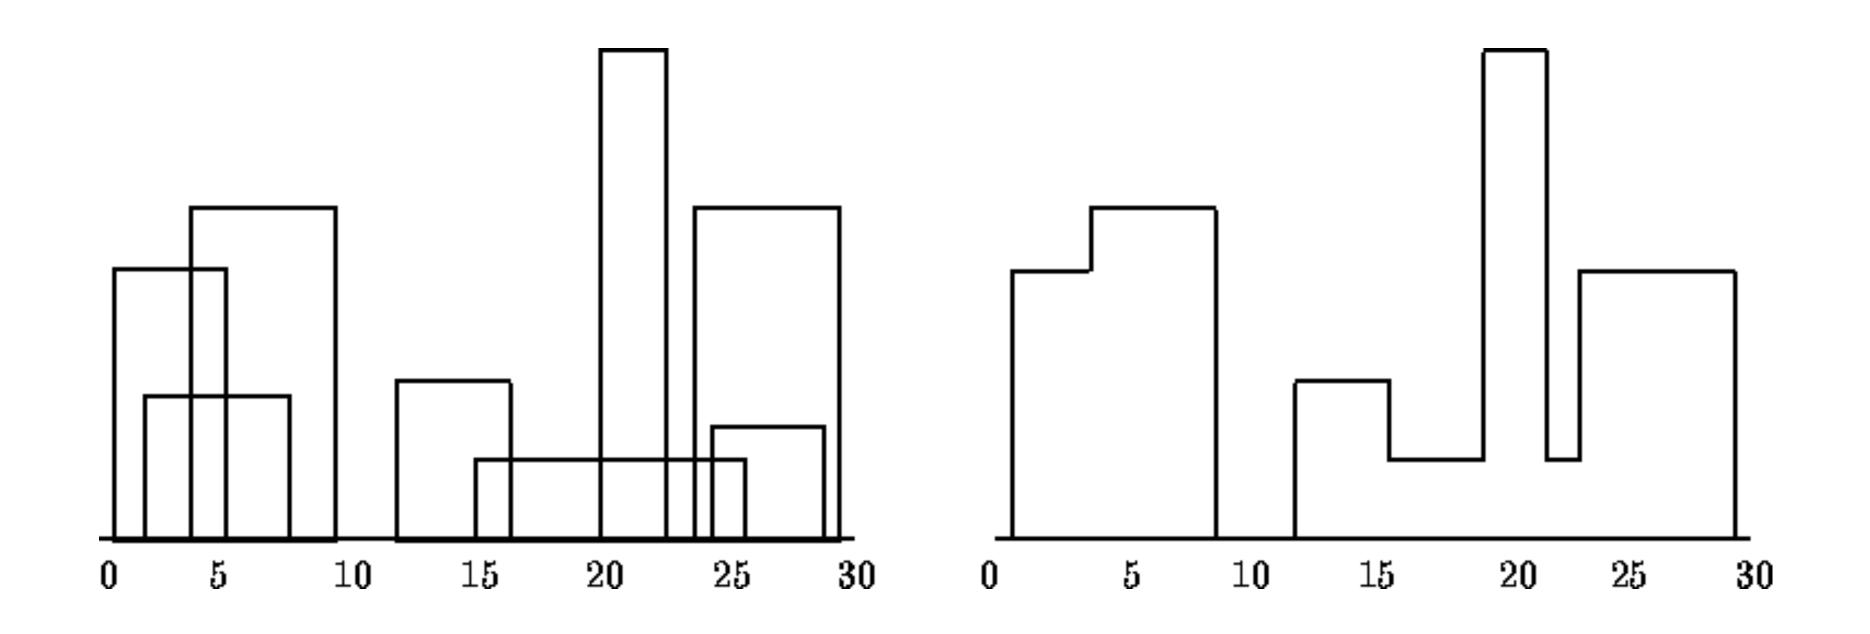
```
class Point implements Comparable<Point> {
    int x;
    int delta;

    Point(int x, int delta) {
        this.x = x;
        this.delta = delta;
    }

    @Override
    public int compareTo(Point o) {
        if (this.x != o.x) return Integer.compare(this.x, o.x);
        return -Integer.compare(this.delta, o.delta);
    }
}
```

Algorithme de Sweep

• Fréquemment utilisé en "computational geometry", par exemple pour calculer une "skyline" au départ d'un semble de rectangle (exercice).



Question2

Vous devez trier un grand tableau qui a pour propriété qu'il ne contient que des valeurs dans l'ensemble $\{0,1,2\}$.

- Quel algorithme de tri suggérez-vous?
- Ecrivez le code.
- Quelle sera la complexité pour trier le tableau?
- Discutez cette complexité par rapport à la borne inférieure d'un algorithme de tri (Proposition 1 pages 280-281).

Warmpup

- · Si je vous dis que je dois trier un ensemble qui contient
- 1x0, 3x1, 2x5, est-ce que vous êtes capables de reconstruire l'input trié?
 - Oui bien sûr: [0,1,1,1,5,5]
- · L'algorithme "counting" sort consiste à reconstruire l'input trié sur base des compteurs

Reconstruction de l'input

- Quelle est la complexité pour reconstruire l'input trié pour des valeurs de compteur k1 x 0, k2 x 1, k3 x 2 ?
 - O(k1+k2+k3)
 - $\Theta(k1+k2+k3)$
 - O(n log(n)) où n=k1+k2+k3
 - Θ (n log(n)) où n =k1+k2+k3



Counting sort

Complexité Counting sort sur des valeurs {0,1,2}

- n = nombre de valeurs à trier
 - O(n)
 - Θ(n)
 - O(n log(n))
 - $\Theta(n \log(n))$
 - O(n²)
 - $\Theta(n^2)$



Est-ce que le counting sort fonctionne toujours ?

- Si je dois trier des valeurs entres 0 et k ? Quelle est la complexité de Counting-sort pour trier n valeurs ?
 - O(n)
 - → Θ(n)
 - O(n+k)
 - → Θ(n+k)
 - O(n log(n))
 - $\Theta(n \log(n))$

woodlap

```
public static void countingSort(int[] values) {
   int[] buckets = new int[100]; // k = 100
   // Count occurrences of each value in the input array
   for (int i : values) {
      buckets[I]++;
   }
   int idx = 0;
   for (int i = 0; i < 100; i++) {
      for (int j = 0; j < buckets[i]; j++) {
        values[idx] = i;
        idx++;
      }
   }
}</pre>
```

More robust counting sort

• Mon input contient seulement trois valeurs possibles $\{20007,1368910,900045\}$, est-ce que je peux adapter counting-sort pour obtenir une complexité de $\Theta(n)$?

• Discutez cette complexité par rapport à la borne inférieure d'un algorithme de tri (Proposition 1 pages 280-281).

Prop1: Aucun algorithme basé sur les comparaisons ne peut garantir pouvoir trier N objets en moins que ~N lg N comparaisons.

- Le counting sort n'est pas basé sur les comparaisons.
- Il fonctionne bien uniquement s'il y a peu de valeurs différentes à trier (= la différence entre la plus grande et la plus petite n'est pas trop grande <= N).

Le mode d'un tableau

Le mode d'un tableau de nombres est le nombre qui apparait le plus fréquemment dans le tableau.

Exemple mode([4,6,2,4,3,1]) = 4.

- Donnez un algorithme efficace pour calculer le mode d'un tableau de n nombres.
- Quid si on sait que le tableau ne contient que des valeurs de 0 à k?

Mode d'un tableau: Solution 1

1. Trier les éléments

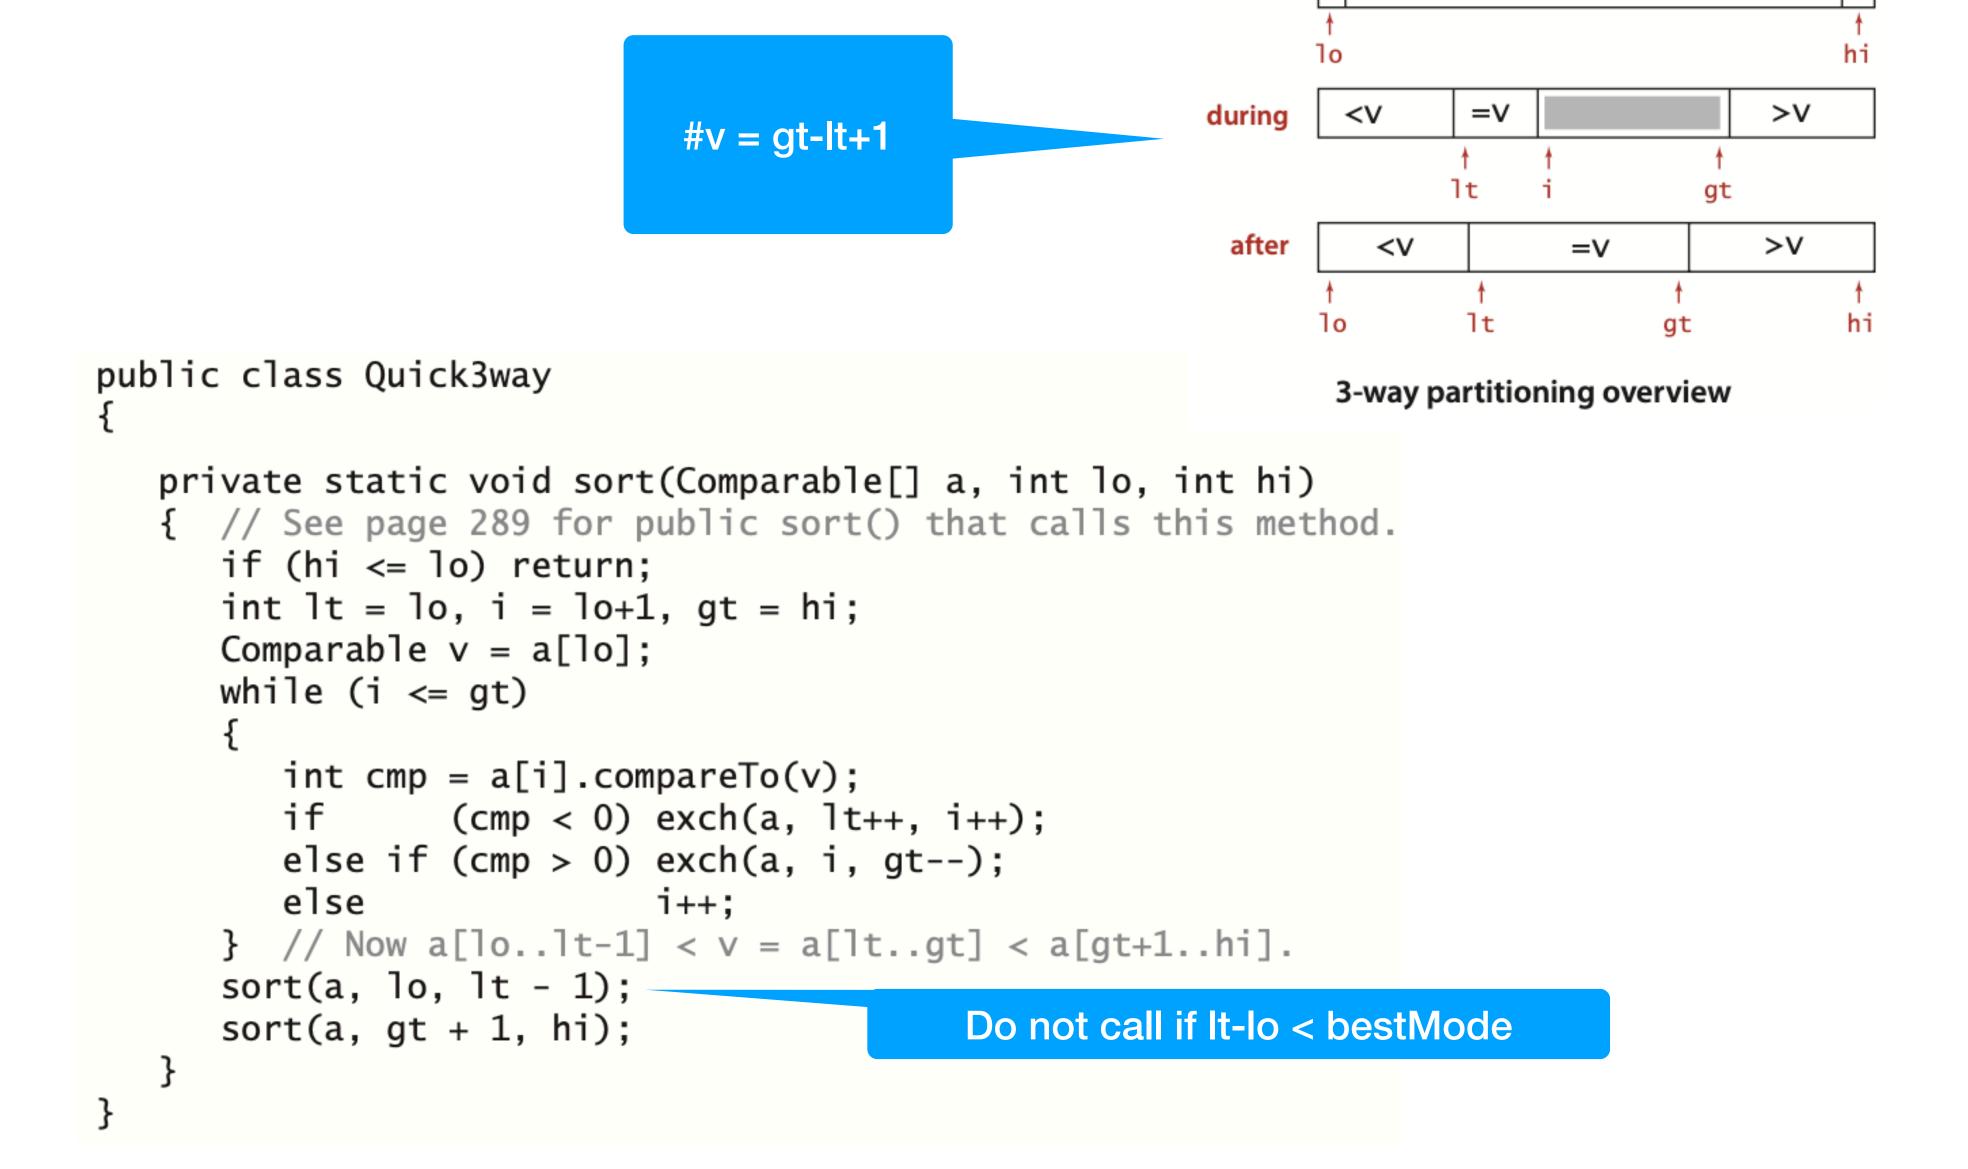
2. Trouver l'élément qui se répète avec le plus de fois consécutivement en parcourant le tableau trié

- Complexité:
 - O(n log(n))
 - $\Theta(n \log(n))$
 - $\Theta(n)$

 - O(n)Θ(n^2)



Recall 3-Way Partitioning



before

Mode d'un tableau: Solution QuickSort

- Lors de l'étape du pivoting (méthode partition), nous pouvons compter le nombre d'éléments qui sont égaux au pivot et maintenir le meilleur candidat mode ainsi que sa fréquence.
- · Cette information peut être utilisée pour éviter des appels récursifs dans quick sort:
 - Un appel récursif est lancé seulement si le sous-tableau à partionner est plus grand que la fréquence du mode courant.

Et si les range des valeurs est entre 0 et k?

 Dans ce cas simplement compter les valeurs dans un tableau de taille k. Si k < n, complexité Θ(n)

Trouver une paire

Étant donné deux ensembles S1 et S2 (chacun de taille n), et un nombre x.

Décrivez un algorithme efficace pour trouver s'il existe une paire (a,b) avec a ∈ S1,b ∈ S2 telle que a+b=x.

Quelle est la complexité de votre algorithme?

Quid si les ensembles sont dans des tableaux déjà triés ?

S1 et S2 sont non triés et taille n

- Trier le premier ensemble S1
- Pour chaque valeur v de S2, on cherche une valeur x-v dans S1 trié avec une recherche dichotomique.
- Complexité ?
 - O(n log(n))
 - $\Theta(n \log(n))$
 - Θ(n)
 - O(n)
 - $\Theta(n^2)$



Quid si les deux ensembles sont déjà triés

- Dans ce cas quelques optimisations peuvent être mises en place mais cela ne change pas la complexité.
- Si pour une valeur v de S1, v+min(S2) > x, il ne faut pas lancer la recherche dichotomique pour les valeurs suivantes plus grandes que v.
- Cela consiste à réduire à l'avance les bornes des deux tableaux
- Exemple: x = 100
- S1=[10,13,46,70,80,101,108]
- S2=[10,22,30,70,82,104,111]

Et pour un seul tableau?

- Trouver deux entrées dont la somme fait x ?
- Exemple [5,10,1,150,151,155,18,50,30] x=68
- Quid si le tableau est déjà trié ?
 - [1,5,10,18,30,50,150,151,155] x=68

Pour un tableau trié

```
/**
* Find a pair (i, j) in array T such that T[i] + T[j] = x.
* @param T An array of integers, sorted in non-decreasing order.
* @param x The target sum.
 * @return An array of two integers i and j if a pair is found, or null otherwise.
public static int[] findPair(int[] T, int x) {
   int i = 0;
   int j = T.length - 1;
   while (i < j) {
       if (T[i] + T[j] > x) {
            j--;
       \} else if (T[i] + T[j] < x) {
           i++;
       } else {
                                                                   Complexité?
           return new int[] {i, j}; // Pair found
   return null; // Pair not found
```

Pourquoi cet algorithme fonctionne-t-il?

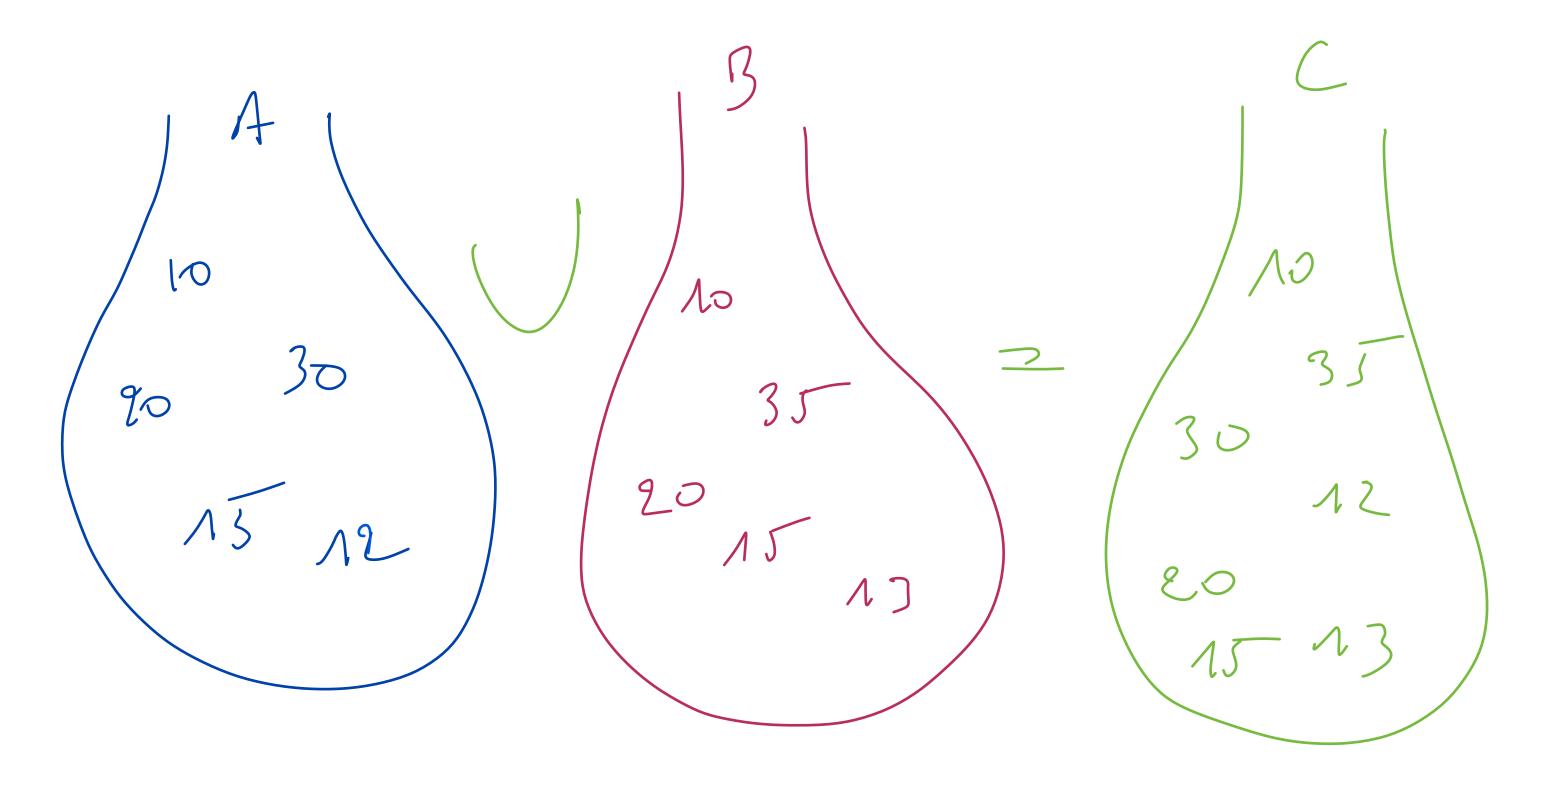
Preuve par induction

- Hypothèse (n'importe quelle paire avec un element avant (<) i ou après (>) j ne fonctionne pas)
- Algo: T[i]+T[j] > x => j = j-1
 - * Il faut montrer qu'il n'existe pas de paire valable avec T[j].
 - * T[j] ne peut être apparié avec un element après i car les valeurs sont triées et ça ne ferait qu'éloigner davantage de x.
 - * Par hypothèse, T[j] ne peut être apparié avec un élément avant i non plus.

Union de tableaux

· Donnez un algorithme pour calculer l'union de deux ensembles A et B.

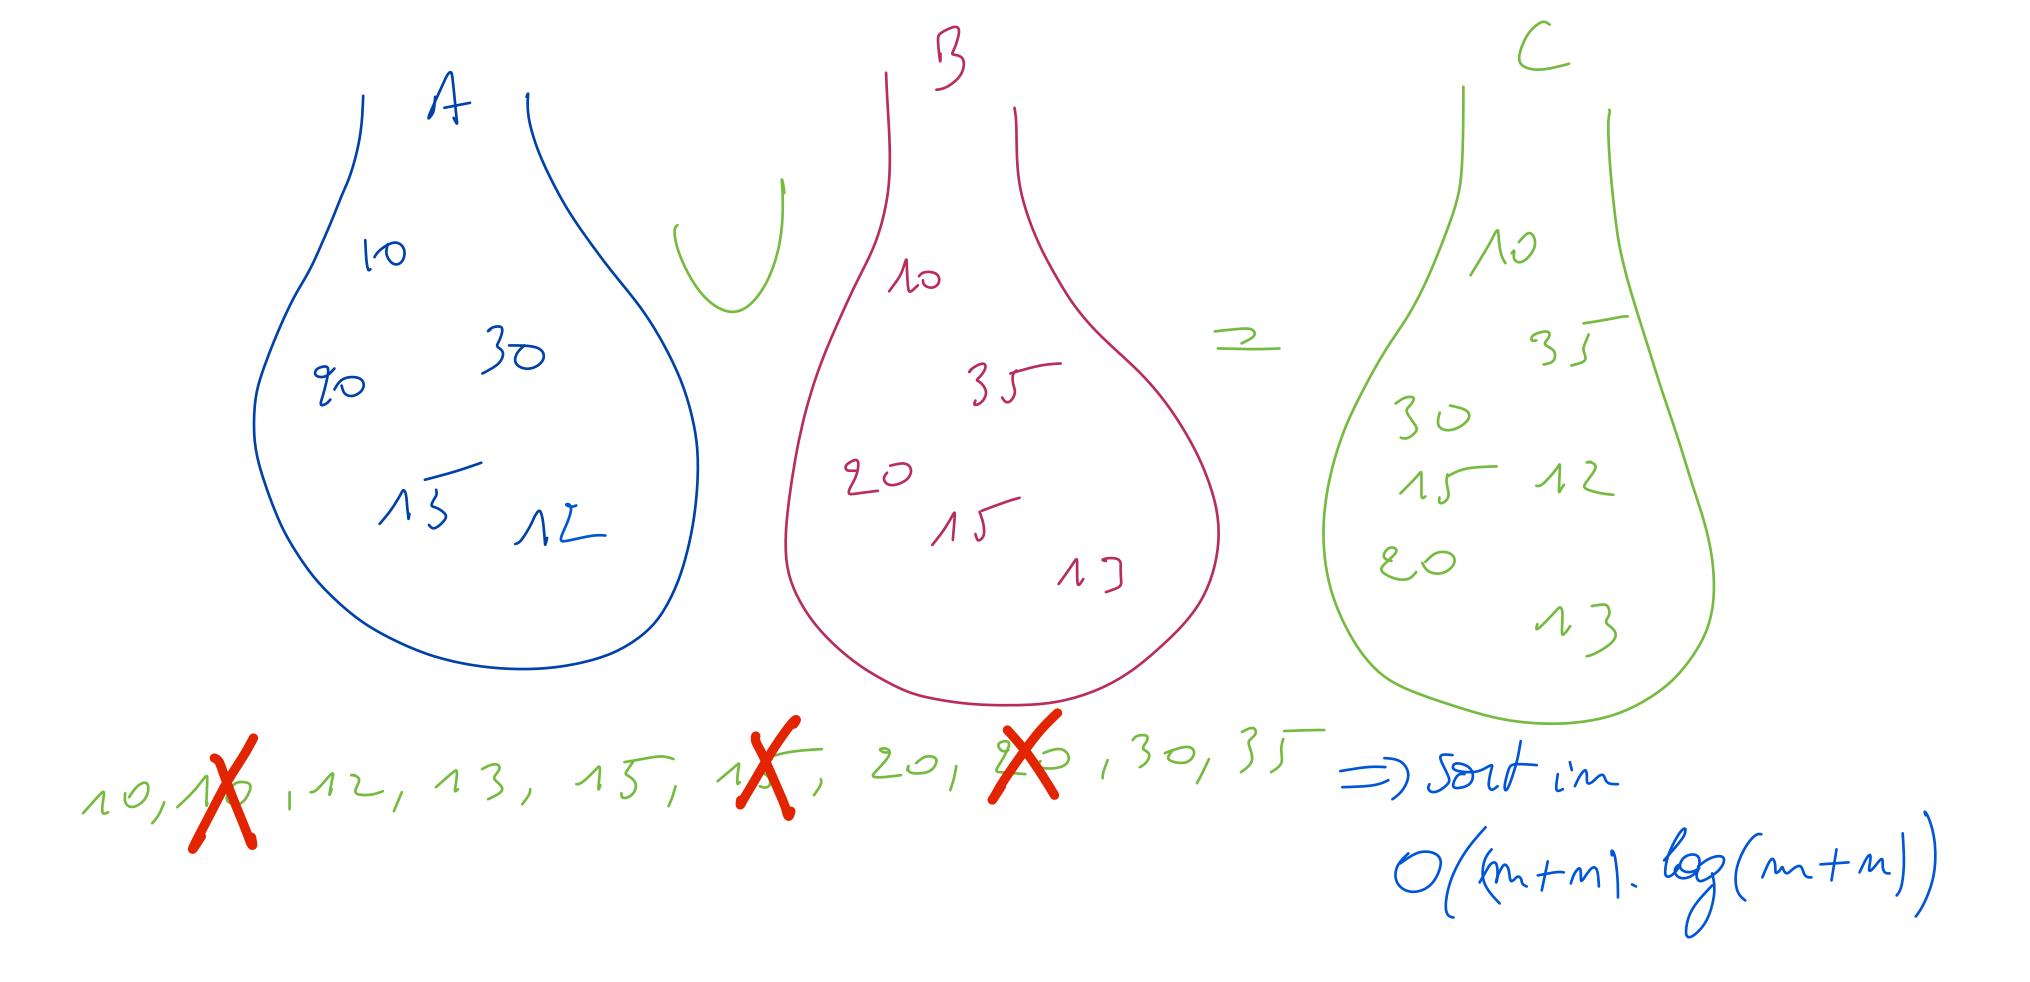
•



Union de deux tableaux: solution 1

· Soit m et n la taille des ensembles

 tout mettre dans un grand tableau et trier O((m+n) log(m+n)) et ensuite retirer les doublons.

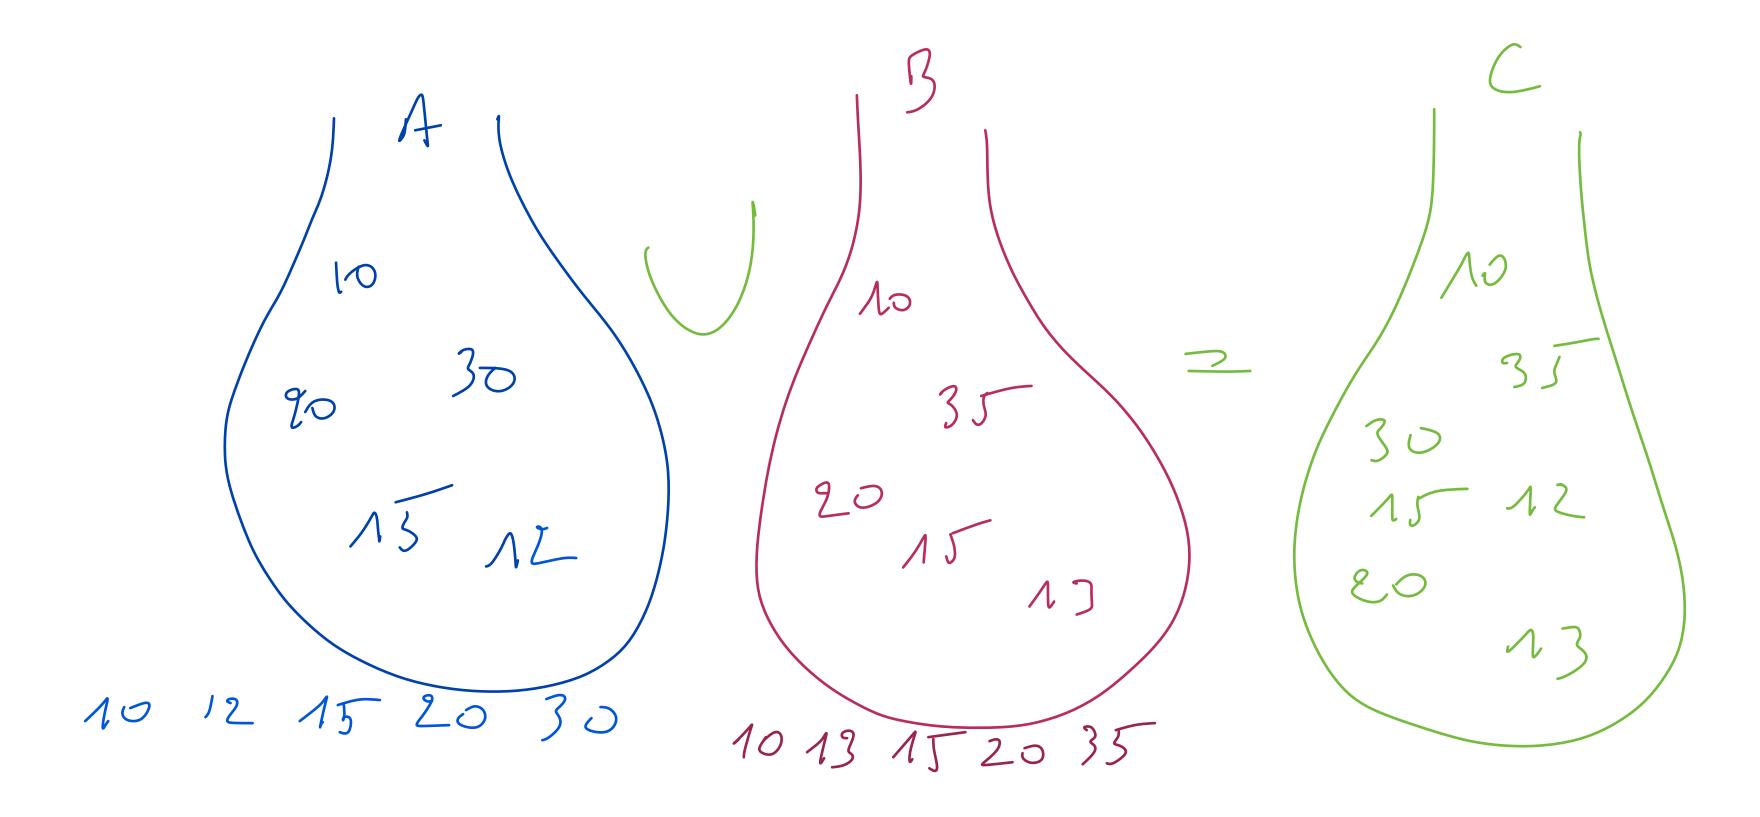


Solution 1

```
public static int[] union(int[] arr1, int[] arr2) {
    int n1 = arr1.length;
    int n2 = arr2.length;
    // Step 1: Concatenate the arrays
    int[] combined = new int[n1 + n2];
    System.arraycopy(arr1, 0, combined, 0, n1);
    System.arraycopy(arr2, 0, combined, n1, n2);
    // Step 2: Sort the array
   Arrays.sort(combined);
    // Step 3: Remove duplicates
    int[] temp = new int[n1 + n2];
   int j = 0;
   for (int i = 0; i < n1 + n2 - 1; i++) {
        if (combined[i] != combined[i + 1]) {
           temp[j++] = combined[i];
   temp[j++] = combined[n1 + n2 - 1]; // Adding the last element
    // Trim temp array to actual size
    int[] result = new int[j];
    System.arraycopy(temp, 0, result, 0, j);
   return result;
```

Union de deux tableaux: solution 2

- Trier chaque ensemble séparément et ensuite collecter les éléments en retirant les doublons. O(m log(m) + n log(n)).
 - Si m = n, Solution1 a la même complexité temporelle que Solution2



Solution 2

```
public static int[] union(int[] arr1, int[] arr2) {
    Arrays.sort(arr1);
    Arrays.sort(arr2);
    int[] temp = new int[arr1.length + arr2.length];
    int i = 0, j = 0, k = 0;
    while (i < arr1.length && j < arr2.length) {</pre>
        // Skip duplicates in arr1
        while (i < arr1.length - 1 && arr1[i] == arr1[i + 1]) {</pre>
            i++;
        // Skip duplicates in arr2
        while (j < arr2.length - 1 && arr2[j] == arr2[j + 1]) {
            j++;
        if (arr1[i] < arr2[j]) {</pre>
            temp[k++] = arr1[i++];
        } else if (arr1[i] > arr2[j]) {
            temp[k++] = arr2[j++];
        } else {
            temp[k++] = arr1[i];
            i++;
            j++;
    while (i < arr1.length) {</pre>
        if (i < arr1.length - 1 && arr1[i] == arr1[i + 1]) {</pre>
            i++;
            continue;
        temp[k++] = arr1[i++];
    while (j < arr2.length) {</pre>
        if (j < arr2.length - 1 && arr2[j] == arr2[j + 1]) {</pre>
            j++;
            continue;
        temp[k++] = arr2[j++];
    int[] result = new int[k];
    System.arraycopy(temp, 0, result, 0, k);
    return result;
```

Union de deux tableaux: solution 3

- Trier seulement un des deux tableaux, pour chaque element du tableau non trié, faire une recherche dichotomique sur le tableau trié pour vérifier s'il faut l'ajouter.
- Est-ce que le tableau qu'il faut trier a de l'importance ?
- · Supposons une grosse différence de tailles sur les tableaux, par exemple de taille n et n^k
 - Pour chaque élément du petit, on fait une recherche dichotomique sur le grand: O(n log(n^k)). Mais il faut trier le grand: O(n^k log (n^k)). Donc au total O(k n^k log (n))
 - Pour chaque élément du grand, on fait une recherche dichotomique sur le petit O(n^k log(n)). Mais il faut trier le petit: O(n.log(n)). Donc au total O(n^k log(n)).
 - Conclusion: si grosses différences de tailles, il vaut mieux trier le petit seulement.

Solution 3

```
public static boolean binarySearch(int[] arr, int target) {
    int left = 0;
    int right = arr.length - 1;
    while (left <= right) {</pre>
        int mid = left + (right - left) / 2;
        if (arr[mid] == target) return true;
        if (arr[mid] < target) left = mid + 1;</pre>
        else right = mid - 1;
   return false;
public static int[] union(int[] arr1, int[] arr2) {
   Arrays.sort(arr1);
    int[] temp = new int[arr1.length + arr2.length];
    int k = 0, i;
    // Add unique elements from arr1 to result
    for (i = 0; i < arr1.length; i++) {</pre>
        if (i == 0 || arr1[i] != arr1[i - 1]) {
            temp[k++] = arr1[i];
    // Check arr2 elements against arr1
    for (int val : arr2) {
        if (!binarySearch(arr1, val)) {
            temp[k++] = val;
    int[] result = new int[k];
    System.arraycopy(temp, 0, result, 0, k);
    return result;
```

Variante du problème

- Supposons dans un second temps, que l'ensemble A déjà trié a une taille n et l'ensemble B également trié a une taille n².
- Quelle seraient la complexité, est-ce que votre algorithme change (think about the merge in a merge sort)?

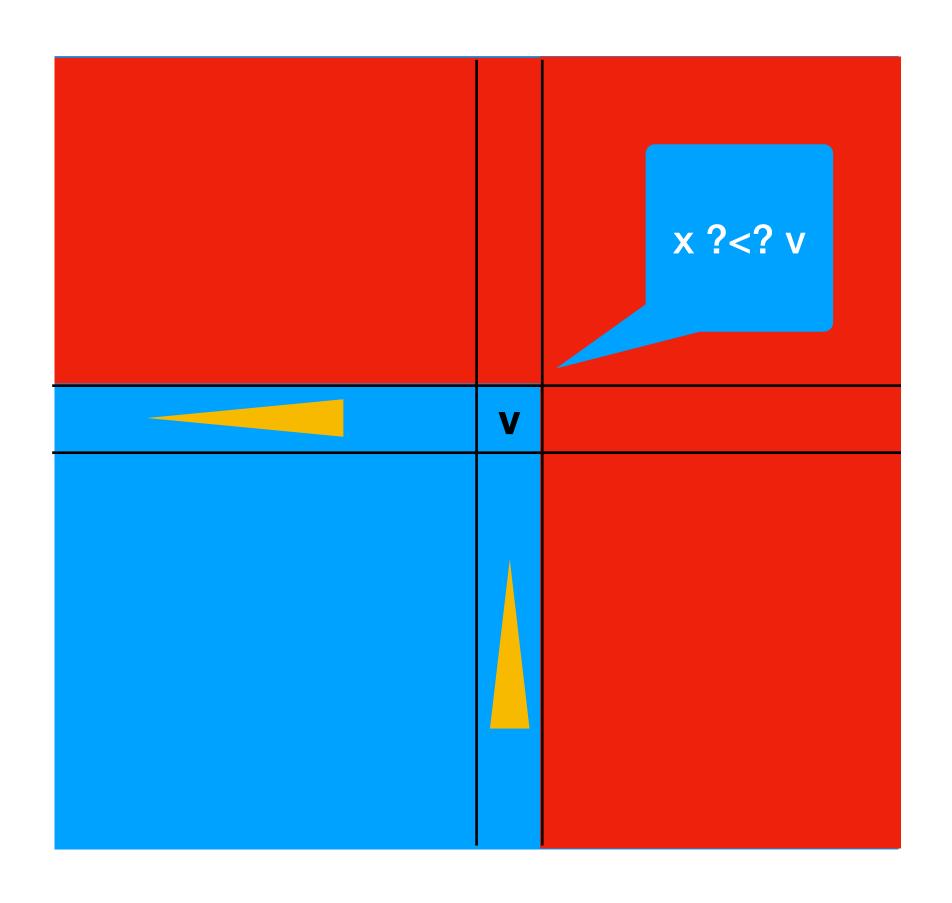
Recherche dans une matrice

• Étant donné une matrice de nombres entiers qui sont triés le long des lignes et des colonnes, comment trouver un nombre donné dans la matrice de manière efficace ?

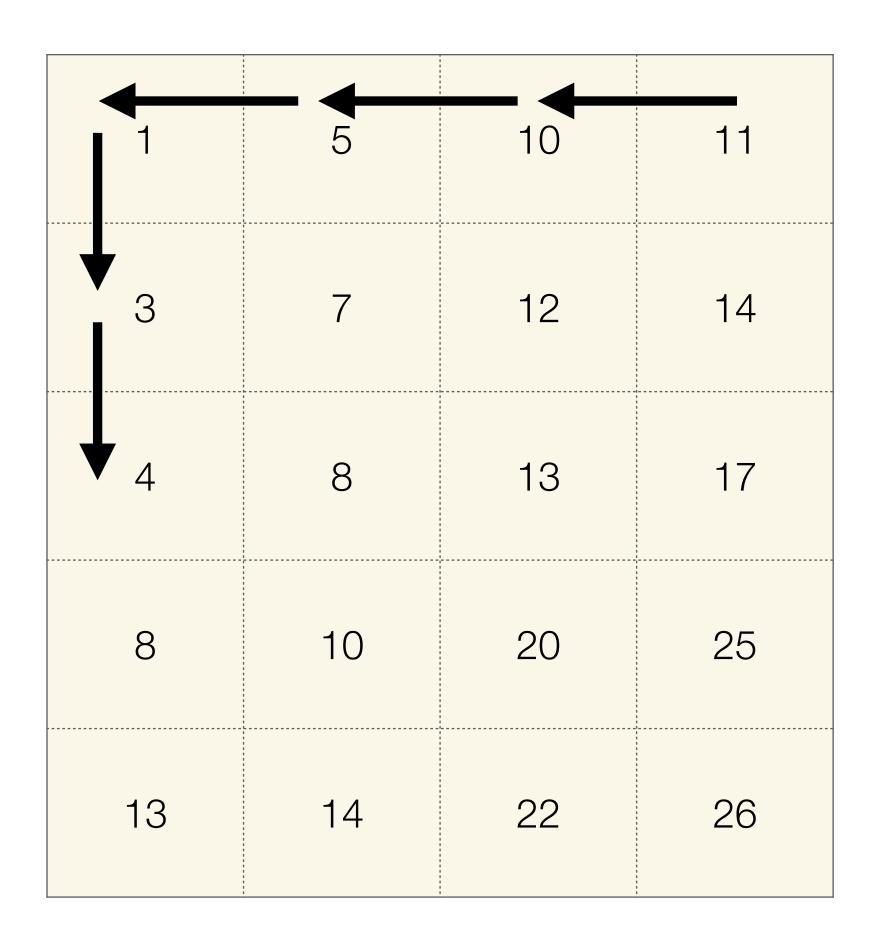
Indice: Il existe un algorithme en temps O(n+m) pour une matrice n x m.

Algo

- Pour cela commencez dans le coin supérieur droit et comparez avec le nombre recherché x.
- Quelles parties de la matrice pouvez-vous élaguer dans votre recherche en fonction du résultat?



• Recherche de 4



• Recherche de 20

1	5	10	11
3	7	12	14
4	8	13	17 ▼
8	10	20	25
13	14	22	26

Pour encore s'entrainer

Réorganiser un tableau d'éléments identifiés par leur couleur, sachant que seules trois couleurs sont présentes (par exemple, rouge, blanc, bleu, dans le cas du drapeau des Pays-Bas).

Votre algorithme doit avoir deux propriétés:

- In place (ne peut créer de nouveau tableau)
- Stable (l'ordre relatif des elements de mêmes couleurs doit être conservé)

Solution 1: Quicksort partition 2 times

```
public static void flagSort(Couleur[] tableau) {
    int i = 0;
    // Partition pour ROUGE
    for (int j = 0; j < tableau.length; j++) {</pre>
        if (tableau[j] == Couleur.ROUGE) {
            // échanger tableau[i] et tableau[j]
            Couleur temp = tableau[i];
            tableau[i] = tableau[j];
            tableau[j] = temp;
            <u>i++;</u>
    // Partition pour BLANC
    for (int j = i; j < tableau.length; j++) {</pre>
        if (tableau[j] == Couleur.BLANC) {
            // échanger tableau[i] et tableau[j]
            Couleur temp = tableau[i];
            tableau[i] = tableau[j];
            tableau[j] = temp;
            i++;
```



In place OK, stable KO

Solution 2

```
public static void flag(Couleur[] tableau) {
    int n = tableau.length;
    int indexRouge = 0; // Position to insert the next ROUGE color
    int indexBleu = n - 1; // Position to insert the next BLEU color
    int i = 0;
    while (i <= indexBleu) {</pre>
        if (tableau[i] == Couleur.ROUGE && i > indexRouge) {
            swap(tableau, i, indexRouge);
            indexRouge++;
        } else if (tableau[i] == Couleur.BLEU && i < indexBleu) {</pre>
            swap(tableau, i, indexBleu);
            indexBleu--;
        } else {
            i++;
public static void swap(Couleur[] tableau, int i, int j) {
    Couleur temp = tableau[i];
    tableau[i] = tableau[j];
   tableau[j] = temp;
```





LINFO 1121 DATA STRUCTURES AND ALGORITHMS



Les arbres de recherches

Pierre Schaus

Les tables de symboles

- Type abstrait de données permettant:
 - D'insérer une valeur avec une clef 🔊
 - Etant donné la clef de retrouver la valeur correspondante

Quelques exemples

Application	Objectif de la recherche	clef	Valeur	
Web search	Trouver des pages intéressantes	Mot-clefs	Liste de pages	
DNS inversé	Trouver l'adresse IP	Nom de domaine	Adresse IP	
Système de fichier	Trouver un fichier	Nom du fichier	Localisation sur le disque	
Compilateur	Trouver les propriété d'une variable	Nom de la variable	Type et valeur	
Table de routage	Trouver un chemin de routage pour un paquet	Destination	Interface de sortie du routeur (meilleure route)	

Un tableau peut être vu comme une table de symboles

	•		4		•
•		Clate	sont	Ind	
	LCO	CICIO	JUIL	HIL	

Les valeurs sont les entrées du tableau

Python adopte cette convention. tab[i] fonctionne pour les tableaux et les dictionnaires

Convention du livre

- · Une clef ne peut se retrouver qu'une seule fois dans la table de symbole.
- Les clefs sont différentes de null et les valeurs également.
 - En effet get(key) retourne null si la clef n'est pas présente
- Etant donné que l'égalité des clefs est basée sur la méthode "equals", il est plus prudent que les clefs soient des objets immuables.

Rappel sur l'égalité et equals

- Propriété demandées:
 - Réflexivité: x.equals(x) est vrai
 - Symétrique: x.equals(y) <=> y.equals(x)
 - Transitivité: x.equals(y) et y.equals(z) => x.equals(z)
 - Non null: x.equals(y) est faux

Exemple

```
public final class Date implements Comparable<Date>
    private final int month;
    private final int day;
    private final int year;
                                                                    Contrat de base
    public boolean equals(Object y)
                                                                         La classe est final donc la
        if (y == this) return true;
                                                                         question ne se pose pas
        if (y == null) return false;
        if (y.getClass() != this.getClass())
            return false;
        Date that = (Date) y;
                                                                       Le cast ne peut pas échouer
        if (this.day != that.day ) return false;
        if (this.month != that.month) return false;
        if (this.year != that.year ) return false;
        return true;
```

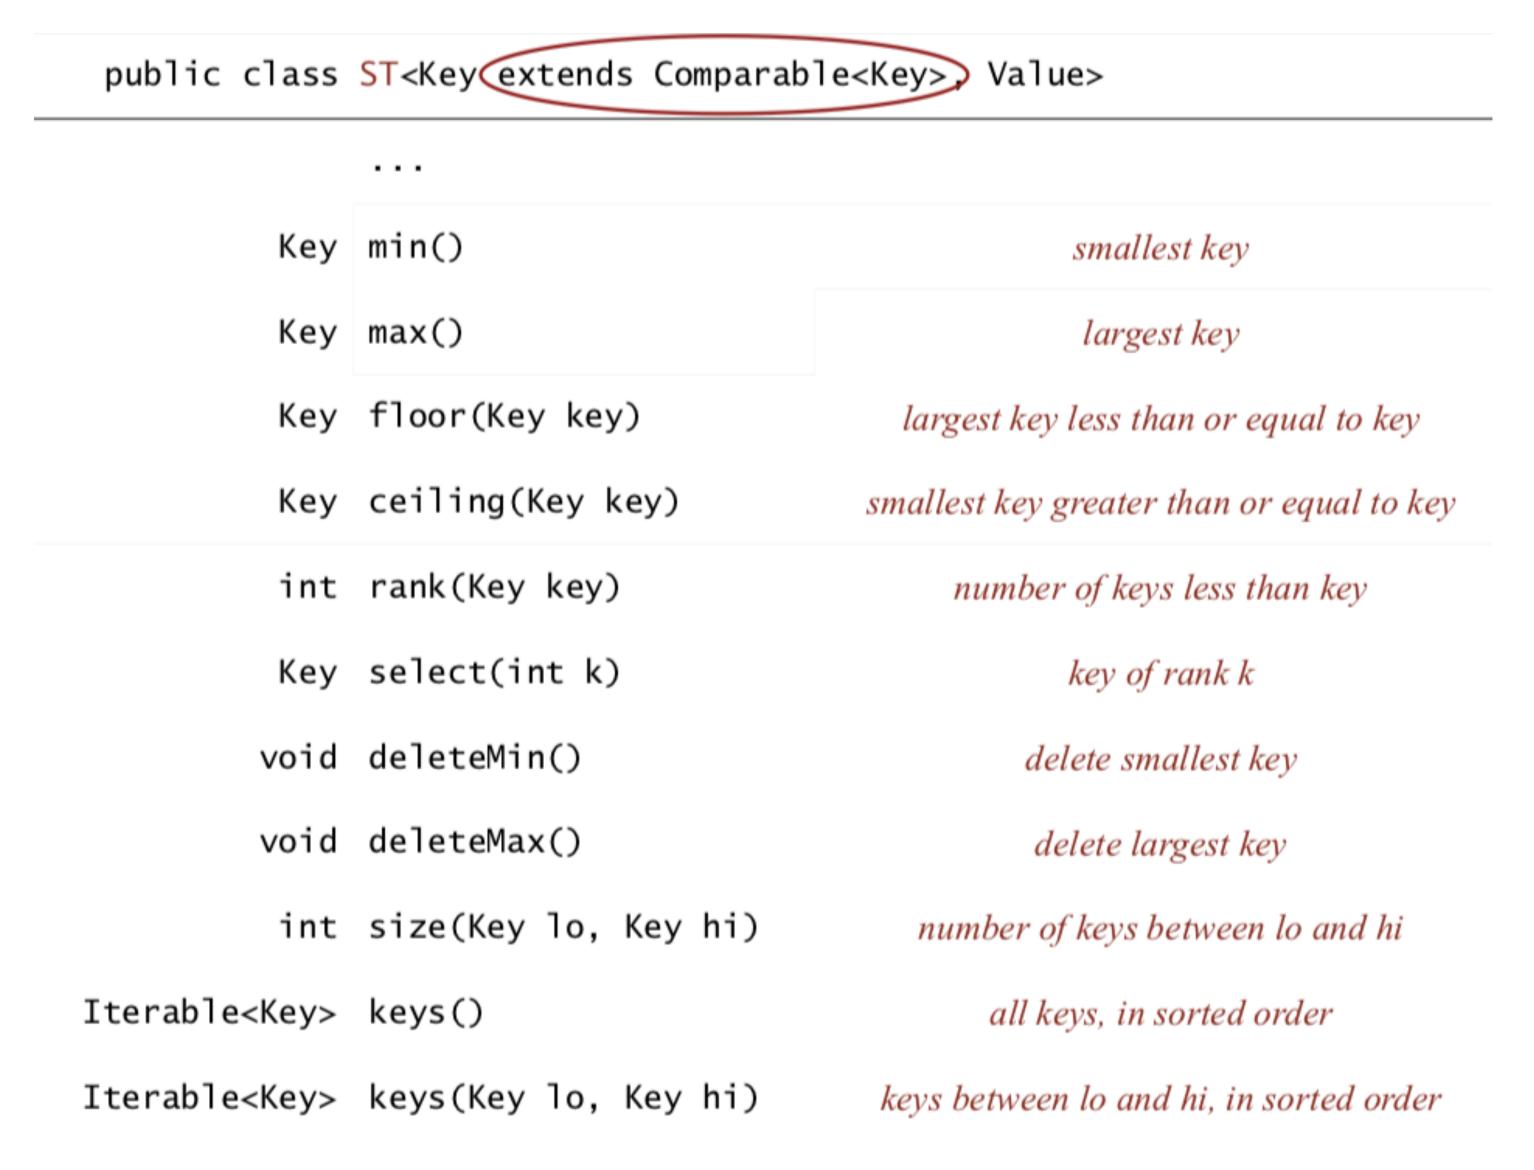
On teste tous les champs.
!!! Ici ce sont des types primitifs !!!
Sinon il aurait fallu utiliser equals et si c'était un tableau, il faudrait tester l'égalité sur chaque élément du tableau (deepEqual)

Implémentation possible des tables de symboles

- · Implémentations possibles pour une tables de symboles:
 - Sequential Search = simple liste chainée qui contient les clefs et les valeurs
 - * insert(key,value) en O(n),
 - * get(key)/delete(key) en O(n)
- En partie 4 nous verrons une autre structure (table de hashage) qui permet O(1) amortie pour toutes les opérations. Patience ...

Relation d'ordre entre les clefs

 Il existe souvent une relation d'ordre entre les clefs. On parle alors généralement de dictionnaire



Utilisation de l'ordre

• Pour améliorer les complexités grâce à la recherche binaire (= dichotomique)

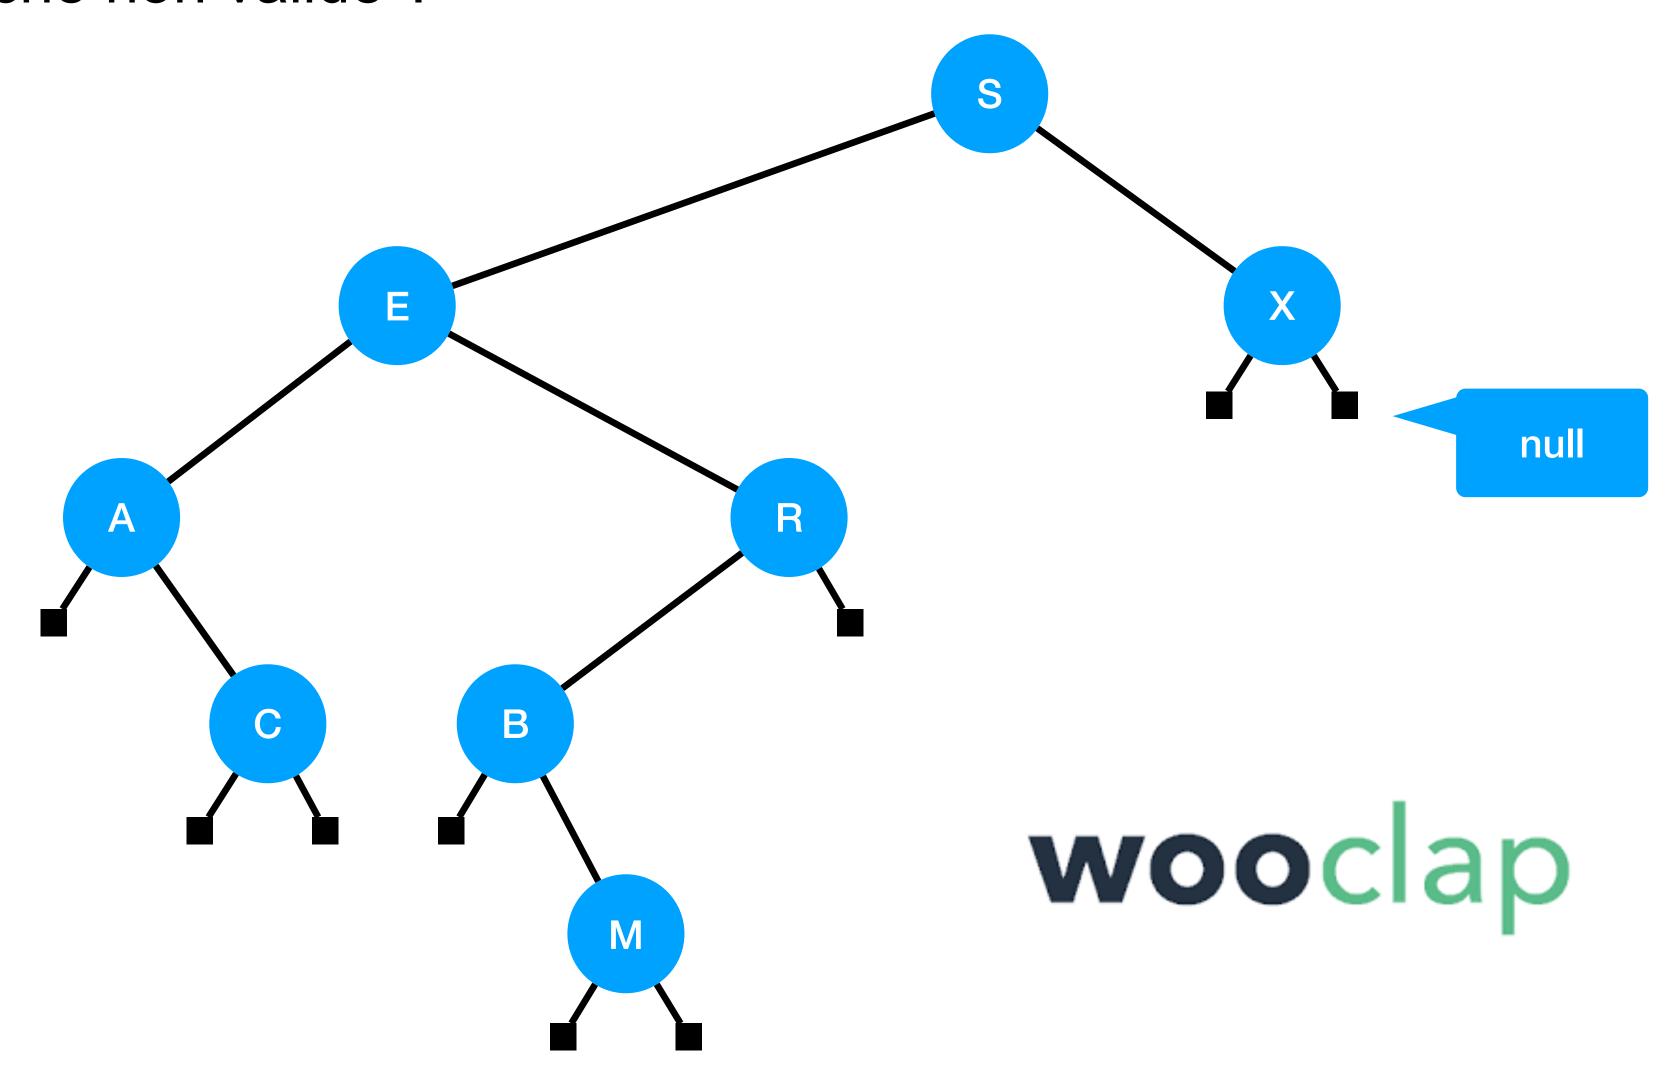
	sequential search	binary search	
search	N	$\log N$	
insert / delete	N	N	On peut encore améliorer grâce à une nouvelle structure de données: Les arbres de recherche
min / max	N	1	
floor / ceiling	N	$\log N$	
rank	N	$\log N$	
select	N	1	
ordered iteration	$N \log N$	N	

Les arbres de recherche

- Arbre binaire:
 - * Vide
 - * Non-vide: Il contient deux arbres binaire (gauche et droit)
- Arbre binaire de recherche = arbre binaire avec une clef-valeur dans chaque noeud telle que
 - * Cette clef est plus grande que toutes les clefs dans le sous arbre de gauche
 - * Cette clef est plus petite que toutes les clefs dans le sous arbre de droite

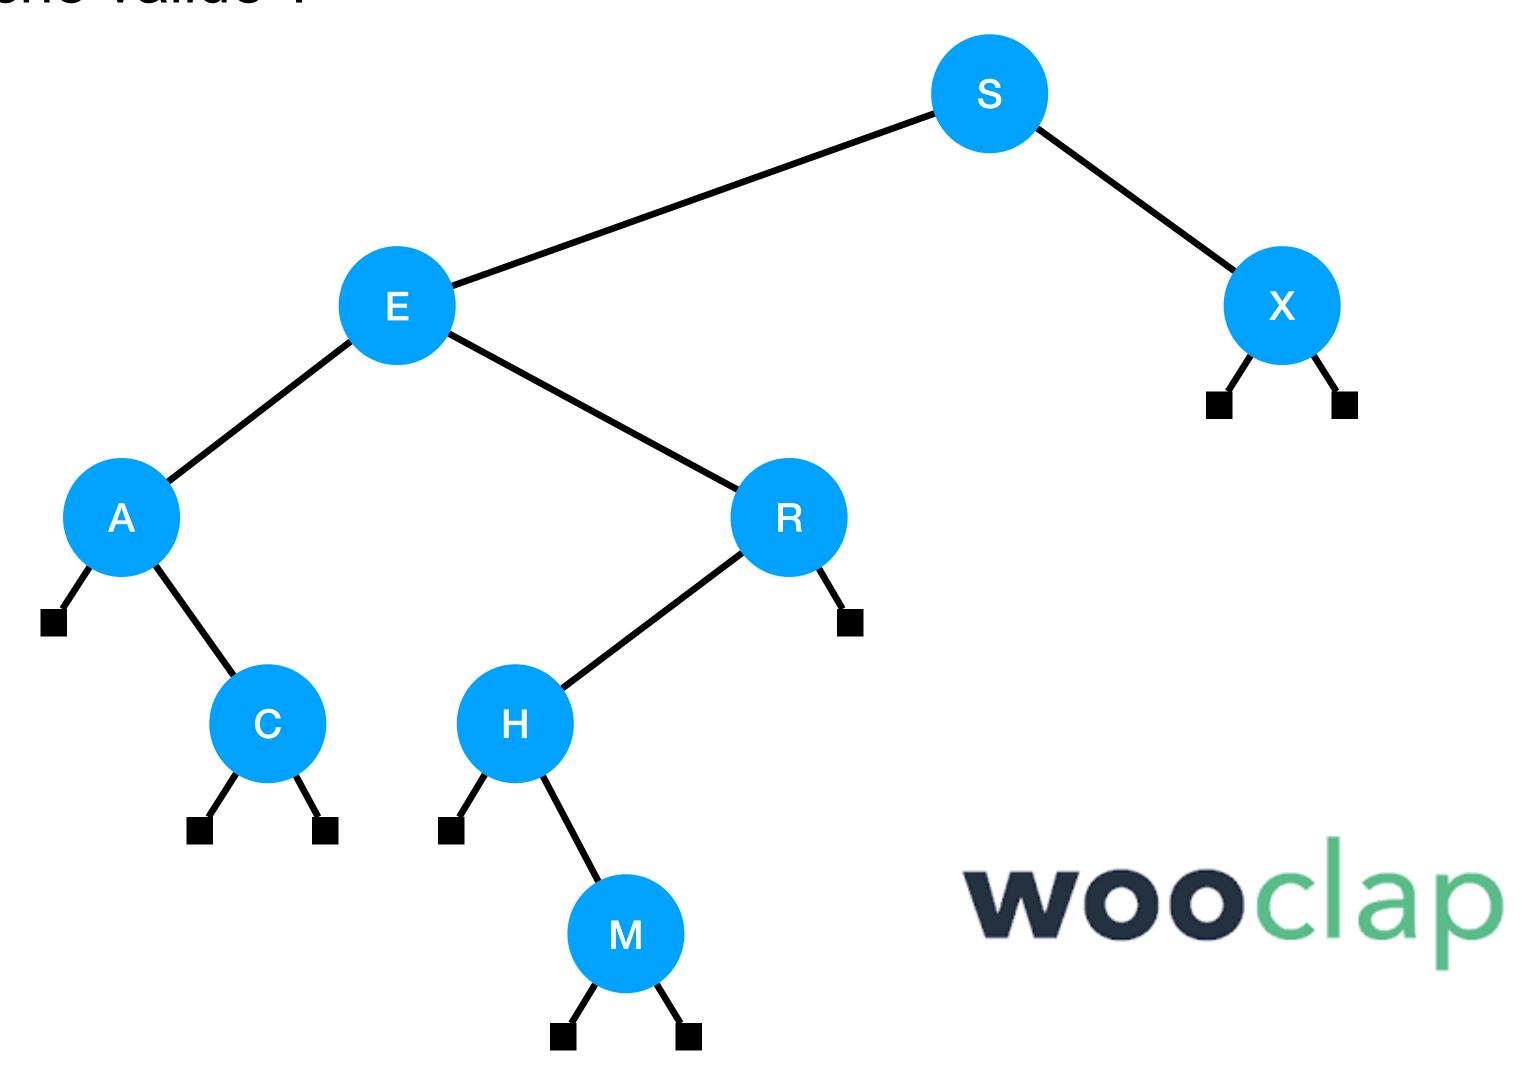
Exemple

Arbre de recherche non valide ?



Exemple

• Arbre de recherche valide ?



Recherche dans un arbre de recherche

♣^N H

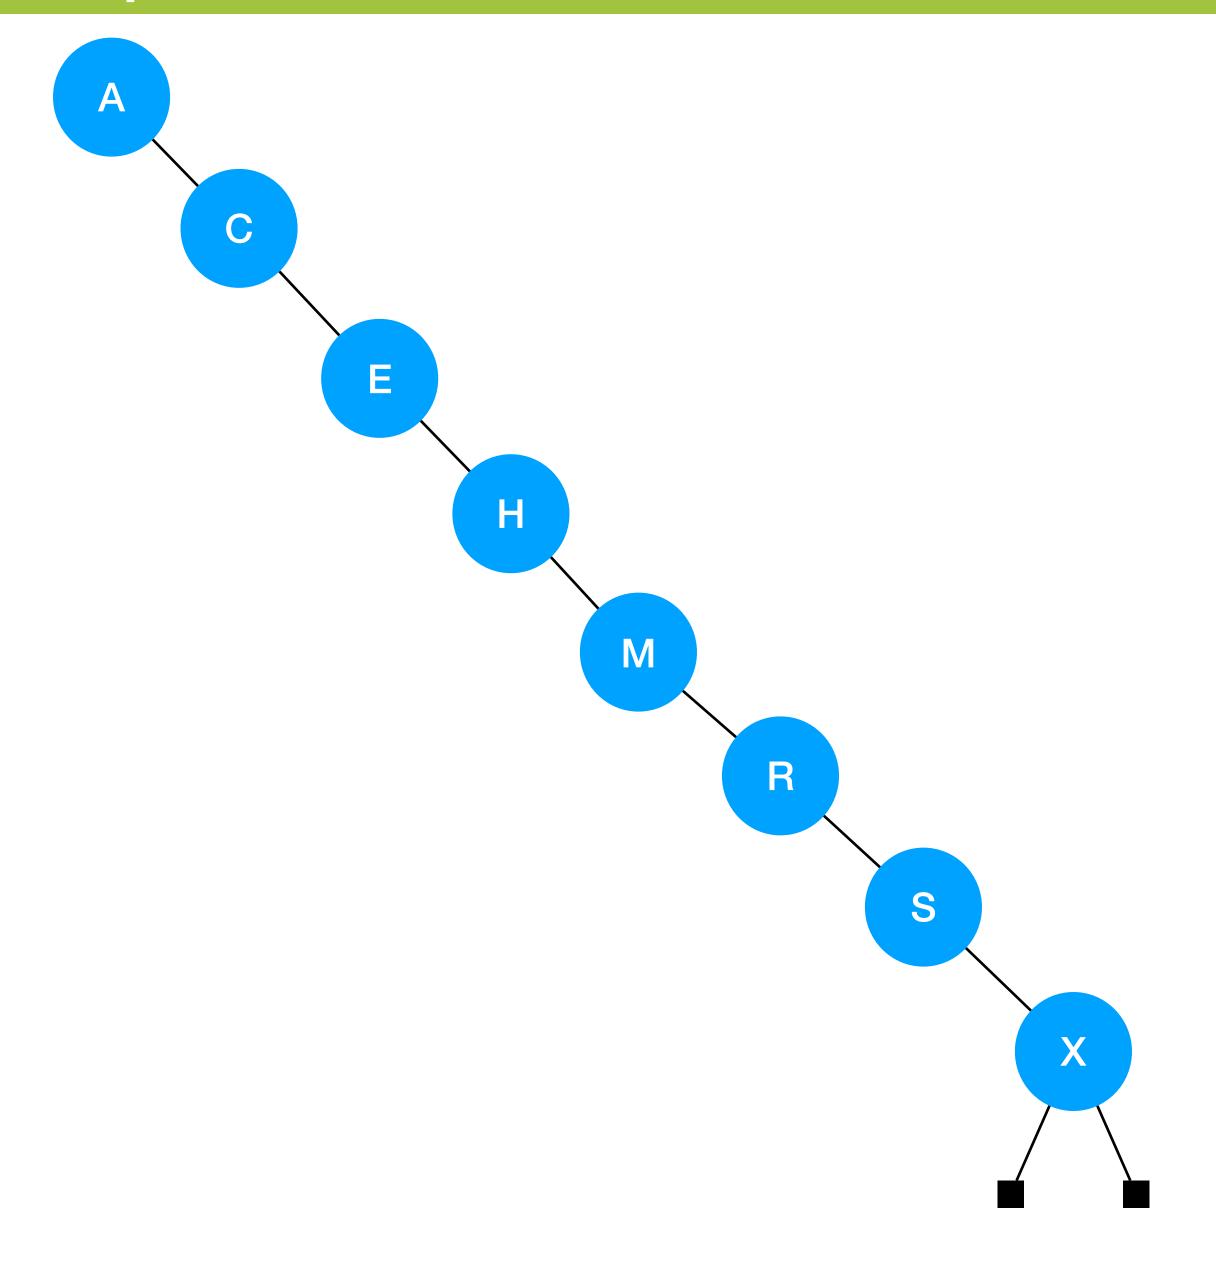
Complexité



- $\Theta(n)$ où n est le nombre de noeuds
- O(log n) où n est le nombre de noeuds
- $\Theta(\log n)$ où n est \triangle ombre de noeuds
- O(h) où h est la hauteur de l'arbre
- $\Theta(h)$ où h est la hauteu e l'arb

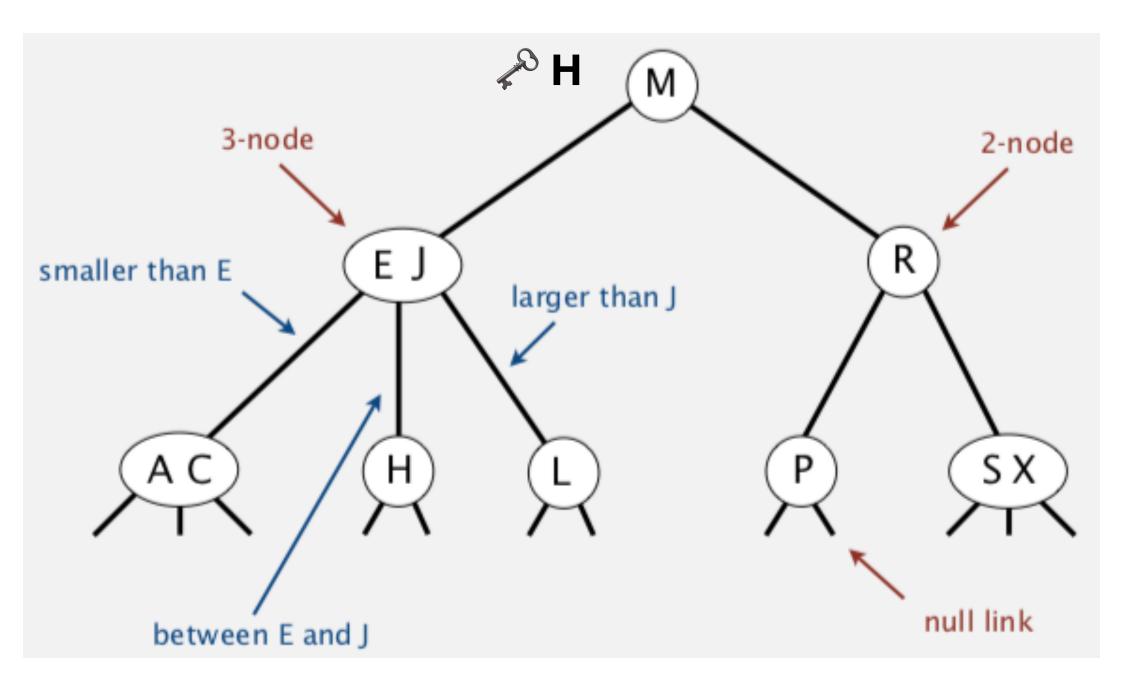


Le pire cas pour la hauteur



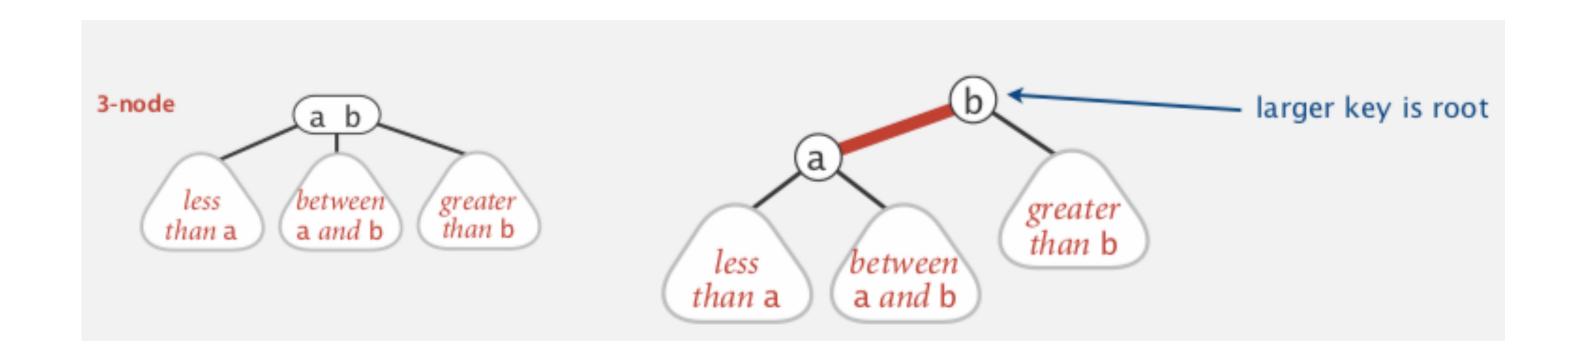
Arbre équilibré O(h) = O(log(n))

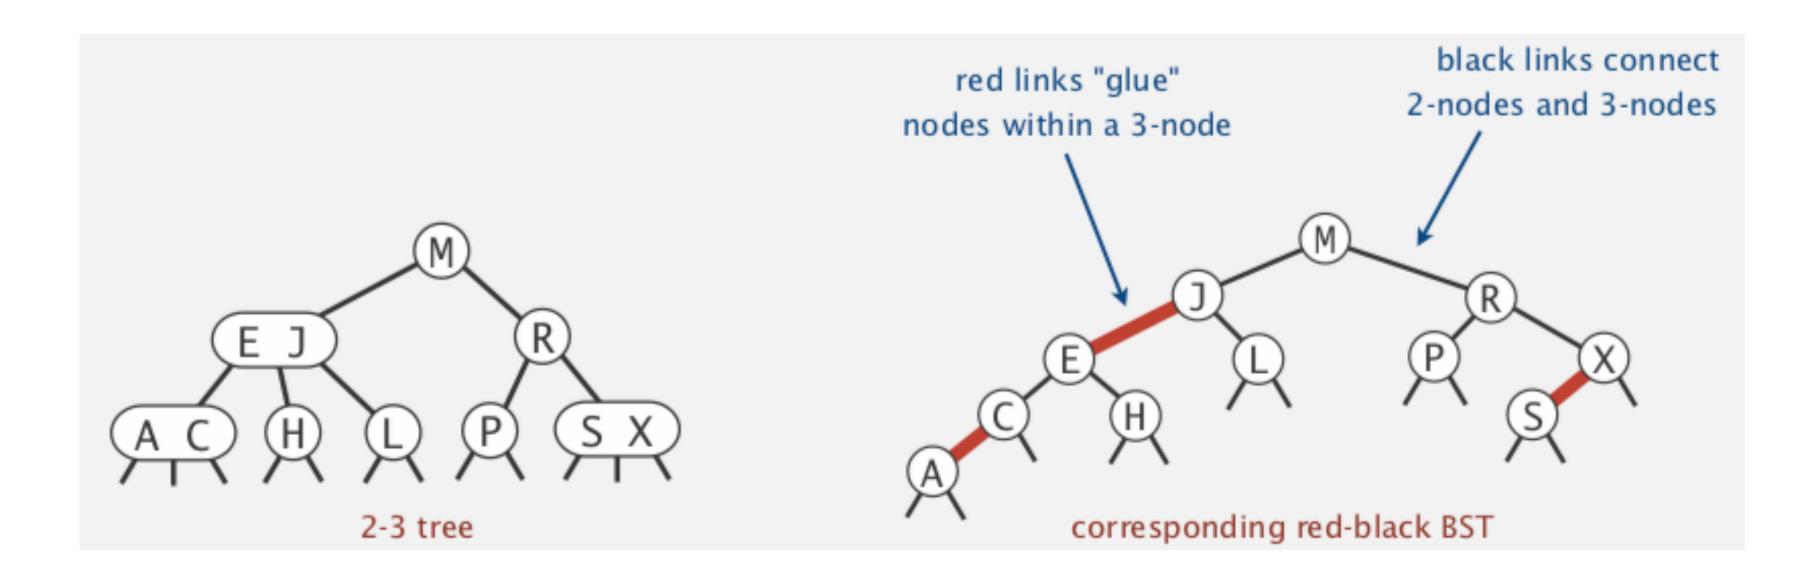
- Arbres 2-3, 1 ou 2 clefs par noeud
 - Equilibre parfait: Chaque chemin depuis la racine vers une feuille (lien null) a exactement la même longueur.
 - L'intérêt c'est que les complexités sont garanties O(log(n)). Effet de la "liste chainée" plus possible.



Arbre équilibré binaire

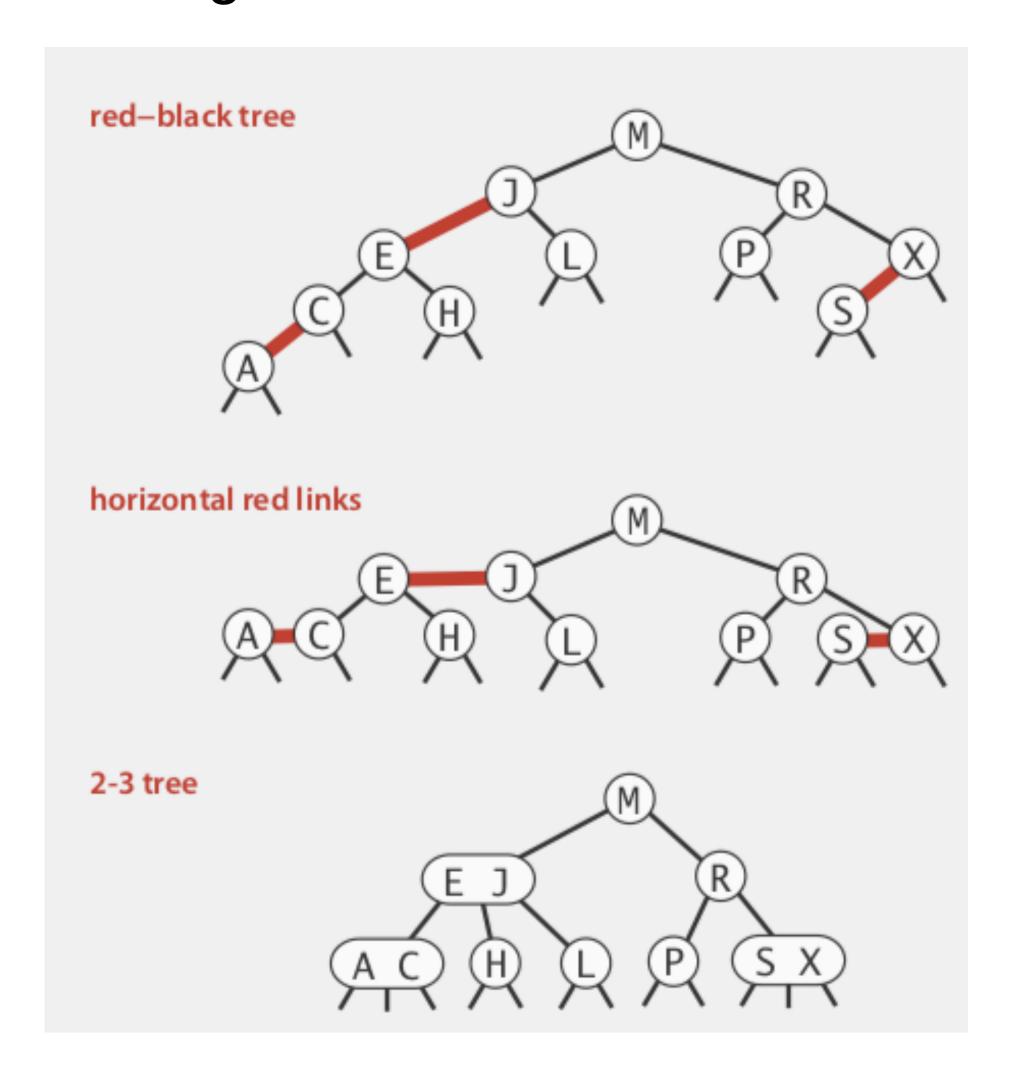
- Arbre red-black penchant à droite
 - = representation d'un arbre 2-3 mais avec un arbre binaire.





Red-black vs 2-3

- La correspondence est parfaite
 - Il suffit de mettre les liens rouge à l'horizontal



Résumé des complexité

implementation	guarantee		
mpiementation	search	insert	delete
sequential search (unordered list)	N	N	N
binary search (ordered array)	lg N	N	N
BST	N	N	N
2-3 tree	c lg N	c lg N	c lg N
red-black BST	2 lg N	2 lg <i>N</i>	2 lg N

Dans les deux semaines qui viennent

- Lecture approfondie des chapitres 3.1, 3.2 et 3.3,
- Exercices théoriques pour maitriser les arbres de recherche et les arbres de recherches équilibrés
- Exercices d'implémentation (part 1-3)
- Mid term test, ne compte dans la note finale que pour 2 points et uniquement s'il fait remonter la note.
 - Inginious le vendredi 3 novembre de 16h à 18h
 - Individuellement: toute tentative de tricherie ou detection de plagiat sera sanctionnée d'un zero pour le cours.

Agenda Reminder

Lecture next week (24h vélo mais on maintient)